Problemi di Render : Parallel Programming for Machine Learning

Lorenzo Baiardi, Thomas Del Moro

10 12 2023

1 Introduzione

In questo elaborato verificheremo l'efficacia dell'utilizzo di metodi di parallelizzazione in problemi comuni, studiandone i risultati, la velocità e i tempi di esecuzione.

2 Analisi del problema

Il problema che abbiamo deciso di valutare è quello del compositing tra piani tramite l'utilizzo della libreria grafica OpenCV. Ogni piano avrà 4 canali di colore (RGBA), e per ogni piano verranno disegnati n cerchi. Durante la fase di sommatoria dei piani, viene applicato un effetto trasparenza in base alla posizione del piano all'interno della sommatoria. Una volta che vengono sommati tutti i piani, tramite operazione di compositing, verrà restituita una matrice risultante con l'immagine finale. I parametri utilizzati all'interno del progetto variano in base ai test effettuati.

Figura 1: Sequenziale

Figura 2: OMP

Figura 3: CUDA

Figura 4: Immagini di esempio con 10000 piani

3 Parallelizzazione

Per poter parallelizzare il problema abbiamo deciso di utilizzare due approcci differenti, nel primo caso abbiamo utilizzato la libreria OPENMP al variare del numero di thread e nel secondo caso abbiamo utilizzato il linguaggio di programmazione CUDA per il calcolo parallelo su scheda grafica. Entrambi i metodi verranno analizzati e confrontati tra loro per verificare quale sia il

più efficiente. Il metodo preso in considerazione per la parallelizzazione è:

```
double sequentialRenderer(cv::Mat planes[], std::size_t nPlanes) {
    cv::Mat result = TRANSPARENT_MAT;
    int cn = result.channels();

    // START
    double start = omp_get_wtime();

    for (int i = 0; i < result.rows; i++) {
        for (int j = 0; j < result.cols; j++) {
            for (int z = 0; z < nPlanes; z++) {
                cv::Mat *src2 = &planes[z];
                for (int c = 0; c < cn; c++)
                    result.data[i * result.step + cn * j + c] =
                            result.data[i * result.step + j * cn + c] * (1 - ALPHA) +
                            src2->data[i * src2->step + j * cn + c] * (ALPHA);
            }
        }
    }

    double time = omp_get_wtime() - start;
    // END

    cv::imwrite(SEQ_IMG_PATH + std::to_string(nPlanes) + ".png", result);
    return time;
}
```

3.1 OPENMP

L'idea di fondo è quella che ogni thread gestisca la sommatoria di un singolo pixel per ogni matrice, in modo da preservare l'ordinamento dei piani ma aumentandone la velocità di render. Di conseguenza ogni thread calcolerà il pixel risultante e successivamente, al termine di esso, passerà al successivo pixel. All'interno dell'esperimento varieremo il numero di thread che il calcolatore potrà utilizzare per la parallelizzazione per verificarne l'efficienza.

```
double parallelRenderer(cv::Mat planes[], std::size_t nPlanes) {
    cv::Mat result = TRANSPARENT_MAT;
    int cn = result.channels();

    // START
    double start = omp_get_wtime();

#pragma omp parallel for default(none) shared(result, planes) firstprivate(nPlanes, cn) collapse(2)
    for (int i = 0; i < result.rows; i++) {
        for (int j = 0; j < result.cols; j++) {
            for (int z = 0; z < nPlanes; z++) {
                cv::Mat *src2 = &planes[z];
                for (int c = 0; c < cn; c++)
                    result.data[i * result.step + cn * j + c] =
                            result.data[i * result.step + j * cn + c] * (1 - ALPHA) +
                            src2->data[i * src2->step + j * cn + c] * (ALPHA);
            }
        }
    }

    double time = omp_get_wtime() - start;
    // END

    cv::imwrite(PAR_IMG_PATH + std::to_string(nPlanes) + ".png", result);
    return time;
}
```

3.2 CUDA

In questo caso la parte di parallelizzazione si svilupperà principalmente nel calcolo di grid e block da utilizzare. Anche in questo caso, ogni thread gestirà un singolo pixel per ogni matrice, in modo da preservare l'ordinamento dei piani ma sfruttando la potenza di calcolo della scheda grafica.

```
__global__ void cudaKernelCombinePlanes(uchar4* resultData, const uchar4* planesData, int width, int height, int nPlanes) {
    auto x = blockIdx.x * blockDim.x + threadIdx.x;
    auto y = blockIdx.y * blockDim.y + threadIdx.y;

    if (x < width && y < height) {
        auto idx = y * width + x;
        for (int z = 0; z < nPlanes; z++) {
            auto idxP = z * width * height + idx;
            resultData[idx].x = resultData[idx].x * (1.0f - ALPHA) + planesData[idxP].x * ALPHA;
            resultData[idx].y = resultData[idx].y * (1.0f - ALPHA) + planesData[idxP].y * ALPHA;
            resultData[idx].z = resultData[idx].z * (1.0f - ALPHA) + planesData[idxP].z * ALPHA;
            resultData[idx].w = resultData[idx].w * (1.0f - ALPHA) + planesData[idxP].w * ALPHA;
        }
    }
}
```

```
// START
double start = omp_get_wtime();

// INITIALIZATION OF GPU MEMORY
cudaMalloc((void**)&d_resultData, width * height * sizeof(uchar4));
cudaMalloc((void**)&d_planesData, width * height * sizeof(uchar4) * nPlanes);

cudaMemcpy(d_resultData, result.data, width * height * sizeof(uchar4), cudaMemcpyHostToDevice);
for (std::size_t i = 0; i < nPlanes; i++)
    cudaMemcpy(d_planesData + i * width * height, planes[i].data, width * height * sizeof(uchar4), cudaMemcpyHostToDevice);

// GRID AND BLOCK DIMENSIONS
dim3 block(16, 16);
dim3 grid((result.cols + block.x - 1) / block.x, (result.rows + block.y - 1) / block.y);

// CUDA KERNEL
cudaKernelCombinePlanes<<<grid, block>>>(d_resultData, d_planesData, result.cols, result.rows, (int) nPlanes);
cudaDeviceSynchronize();

double time = omp_get_wtime() - start;
// END

// COPY RESULT FROM GPU TO CPU
cudaMemcpy(result.data, d_resultData, width * height * sizeof(uchar4), cudaMemcpyDeviceToHost);
```

4 Tests

I test sono stati effettuati N volte variando il numero e le dimensioni dei piani, il numero di cerchi disegnati per piano e limitando il numero di thread da poter eseguire alla volta. I cerchi che dovranno essere disegnati sono generati precedentemente all'esecuzione del test, verificando così se i risultati delle varie operazioni riportino una soluzione identica.

4.1 Risultati

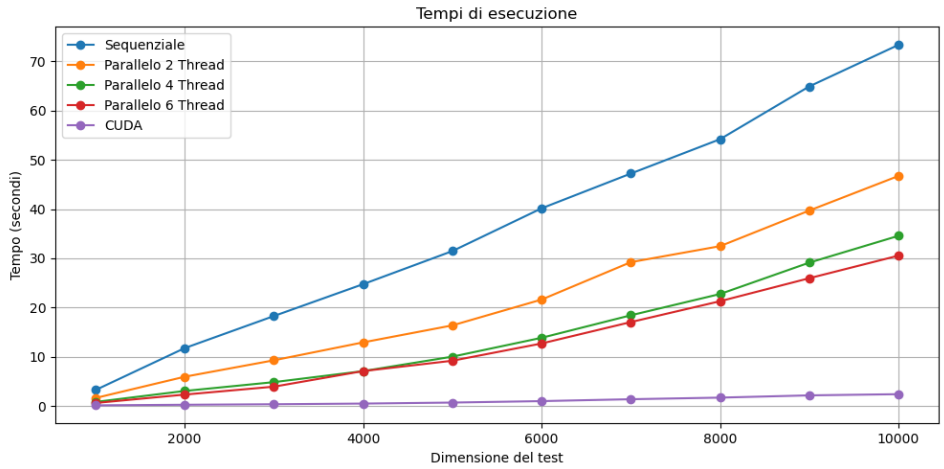

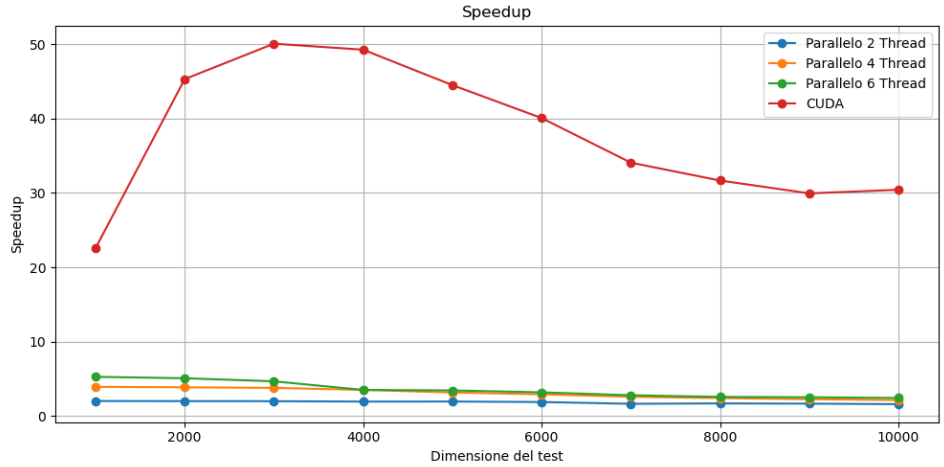

5 Conclusioni

In conclusione, possiamo vedere come l'operazione di parallelizzazione CUDA risulti il più efficiente, a discapito però nel avere a disposizione una scheda grafica NVDIA. Nonostante ciò, anche la parallelizzazione tramite OPENMP risulta molto efficiente rispetto alla formulazione sequenziale.

test	seq	par	speedUp
1000	3.251	1.632	1.992
2000	11.766	5.952	1.977
3000	18.281	9.291	1.968
4000	24.751	12.929	1.914
5000	31.467	16.377	1.921
6000	40.148	21.621	1.857
7000	47.208	29.218	1.616
8000	54.180	32.463	1.669
9000	64.901	39.696	1.635
10000	73.335	46.719	1.570

Tabella 1: 2 thread

test	seq	par	speedUp
1000	3.251	0.834	3.900
2000	11.766	3.063	3.841
3000	18.281	4.856	3.764
4000	24.751	7.092	3.490
5000	31.467	10.029	3.138
6000	40.148	13.859	2.897
7000	47.208	18.426	2.562
8000	54.180	22.748	2.382
9000	64.901	29.120	2.229
10000	73.335	34.563	2.122

Tabella 2: 4 thread

test	seq	par	speedUp
1000	3.251	0.619	5.251
2000	11.766	2.327	5.055
3000	18.281	3.937	4.643
4000	24.751	7.101	3.486
5000	31.467	9.200	3.420
6000	40.148	12.705	3.160
7000	47.208	17.049	2.769
8000	54.180	21.285	2.545
9000	64.901	25.955	2.501
10000	73.335	30.540	2.401

Tabella 3: 6 thread

test	seq	cuda	speedUp
1000	3.251	0.144	22.558
2000	11.766	0.260	45.332
3000	18.281	0.365	50.098
4000	24.751	0.502	49.288
5000	31.467	0.707	44.521
6000	40.148	1.002	40.084
7000	47.208	1.385	34.083
8000	54.180	1.710	31.675
9000	64.901	2.167	29.948
10000	73.335	2.410	30.433

Tabella 4: CUDA